

Unipar - Universidade Paranaense

DEEP LEARNING NO RECONHECIMENTO DE IMAGENS

ARQUITETURAS E DESEMPENHOS

Paranavaí, novembro de 2025

Maria Eduarda de A Gonçalves RA:230446-1

Orientador: Prof. Marco Antonio Ribeiro

Artificial Intelligence

Machine Learning

Deep Learning

INTRODUÇÃO

- A inteligência artificial tem avançado rapidamente.
- O reconhecimento de imagens é essencial em áreas como segurança, medicina e indústria.
- O Deep Learning tornou possível extrair padrões complexos em imagens com alta precisão.
- Redes neurais profundas simulam o funcionamento do cérebro humano.

OBJETIVO

- Analisar e comparar diferentes arquiteturas de **Deep Learning** aplicadas ao reconhecimento de imagens.
- Avaliar **desempenho, acurácia e eficiência** computacional.
- Foco nas arquiteturas **ResNet50**  e **MobileNetV2** 



JUSTIFICATIVA

- Como sistemas inteligentes de visão computacional são cada vez mais usados.
- É importante compreender qual arquitetura entrega melhor desempenho.
- A pesquisa contribui para otimizar aplicações em tempo real, como câmeras diagnósticos.

cenário / aplicação/ recurso comp/ disp. móveis/ tempo real



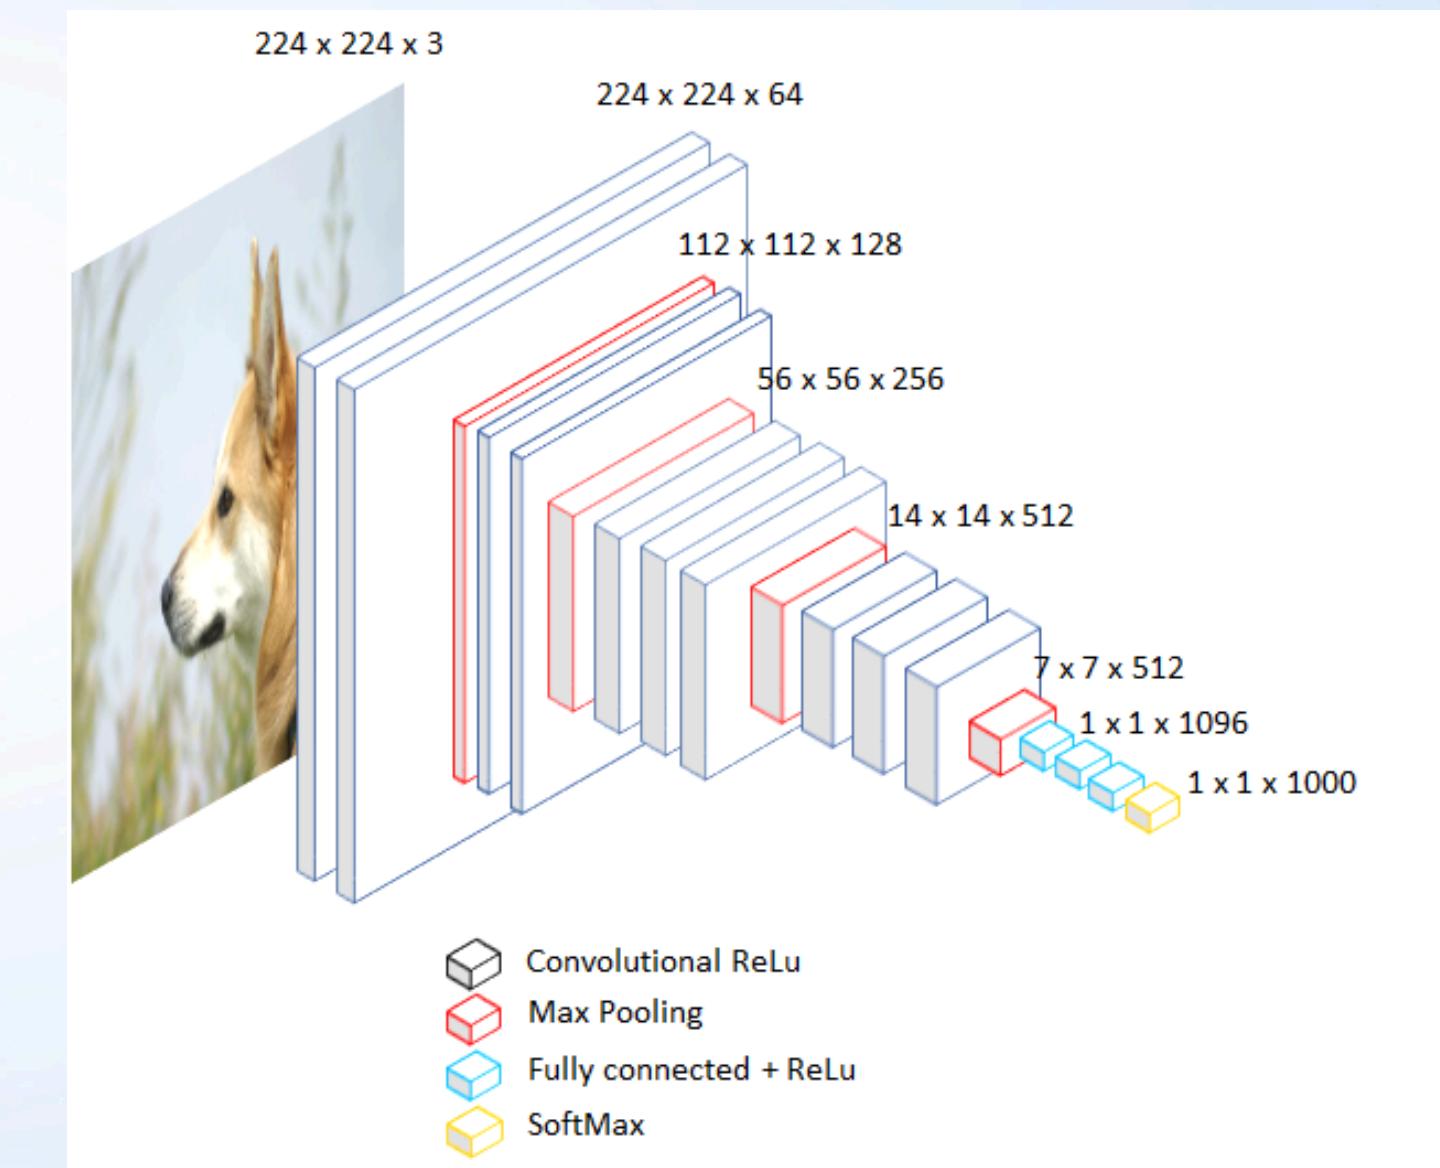
FUNDAMENTAÇÃO TEÓRICA

- **IA:** busca reproduzir a capacidade humana de pensar e aprender.
- **Machine Learning:** permite que máquinas aprendam com dados.
- **Deep Learning:** usa redes neurais profundas para aprender padrões automaticamente.
- Avanços impulsionados pelo aumento da capacidade computacional.



REDES NEURAIS CONVOLUCIONAIS (CNNS)

- **CNNs** são redes específicas para imagens e vídeos.
- Utilizam camadas convolucionais e filtros (kernels) para extrair características.
- Detectam bordas, formas, texturas e objetos completos.
- Base das principais arquiteturas modernas de reconhecimento visual.



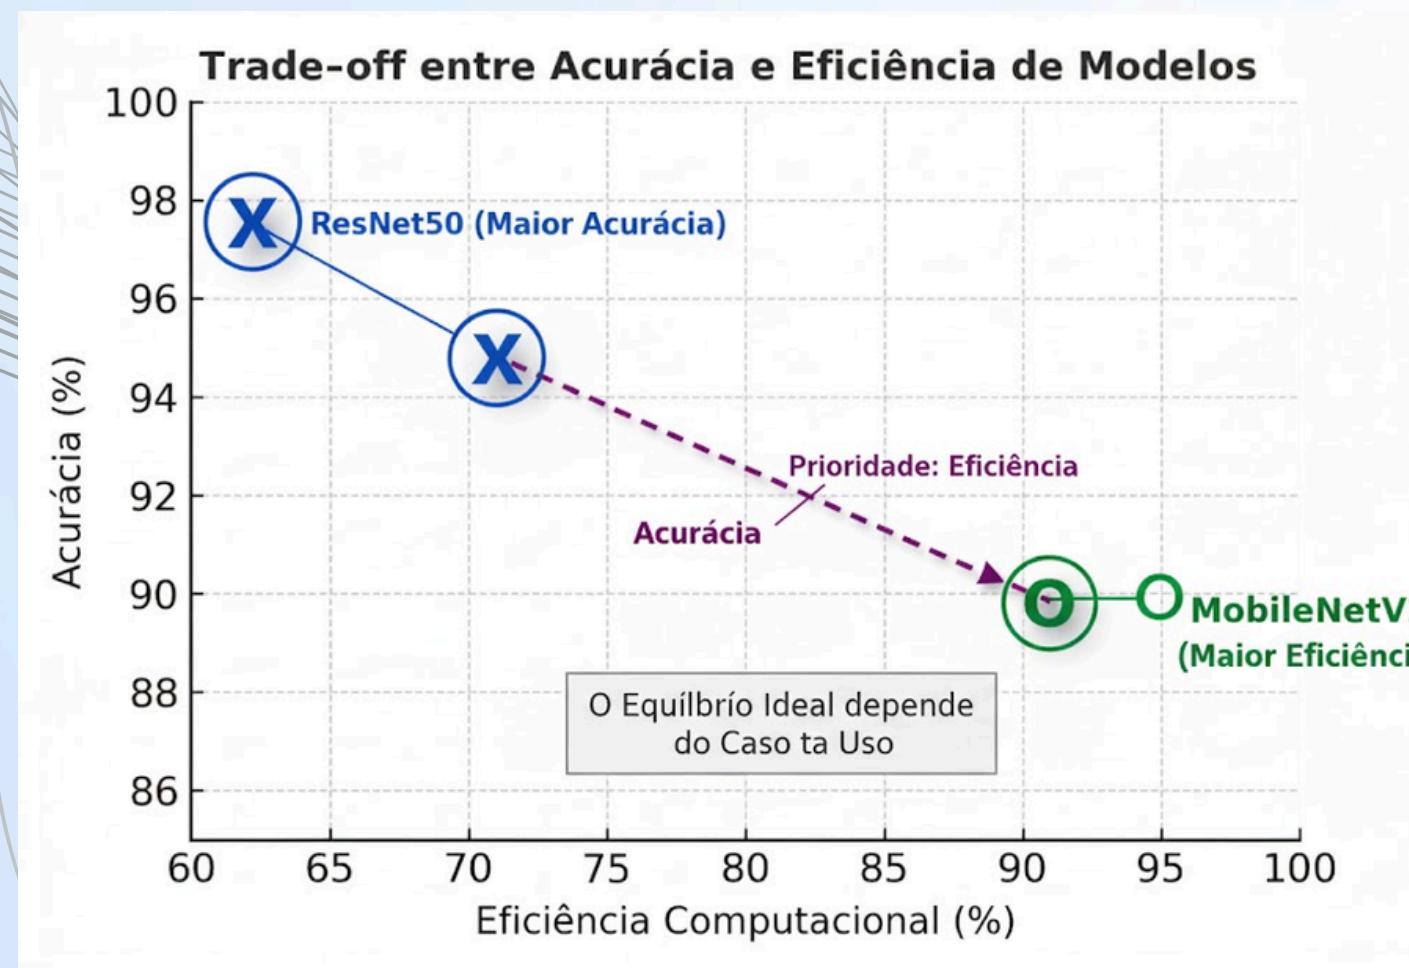
ARQUITETURAS AVALIADAS

RESNET50

- Rede profunda com conexões residuais.
- Alta precisão e ótimo desempenho em grandes conjuntos de dados.

MOBILENETV2

- Estrutura mais leve e eficiente.
- Ideal para dispositivos móveis e aplicações em tempo real.



Exemplos práticos:

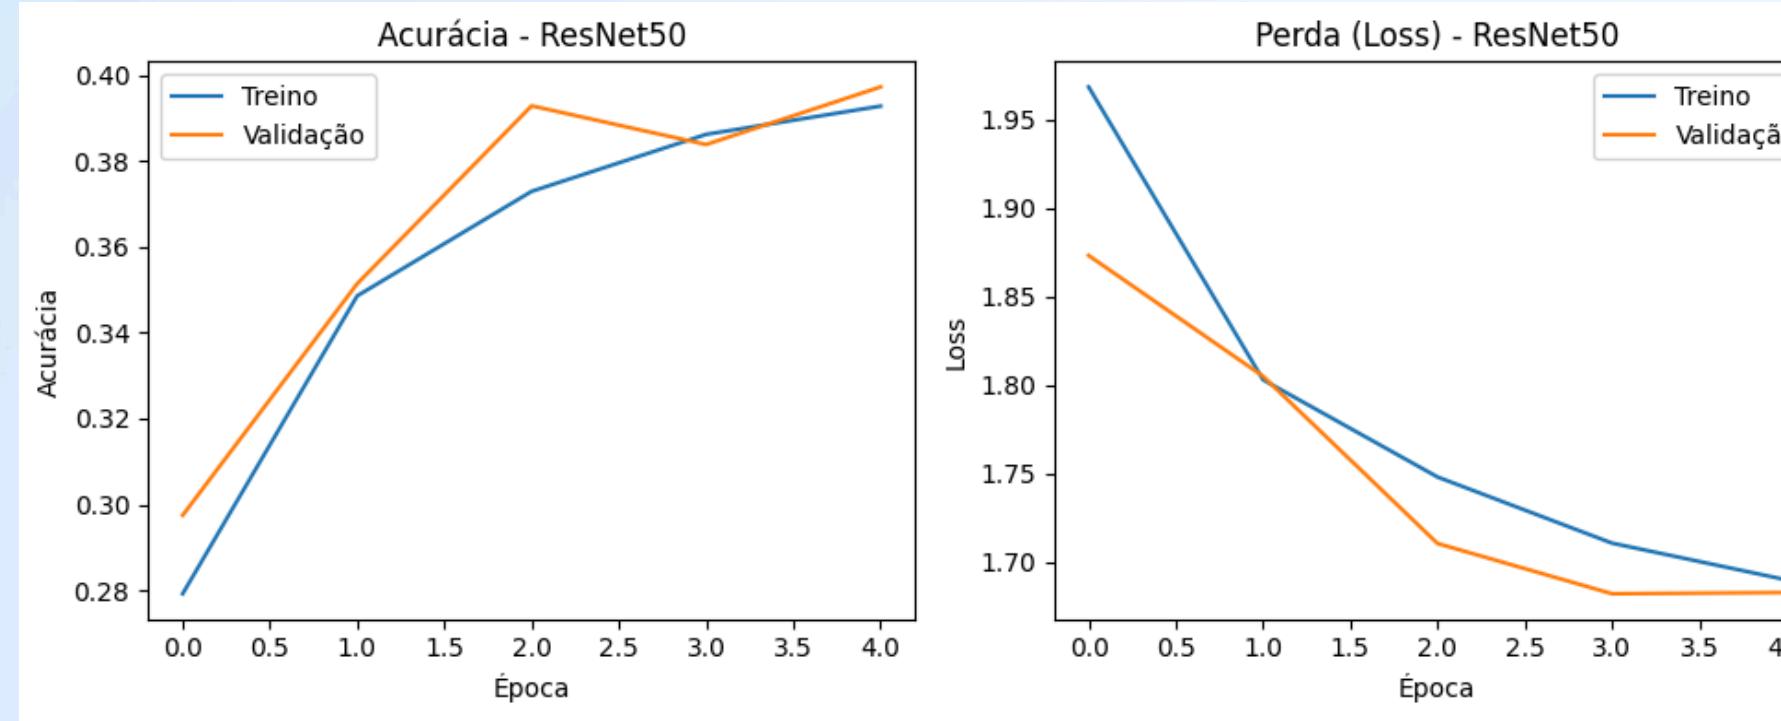
- **ResNet50** em hospitais para leitura de imagens médicas (quando há GPU potente).
- **MobileNetV2** em apps móveis que fazem detecção de objetos em tempo real.

METODOLOGIA

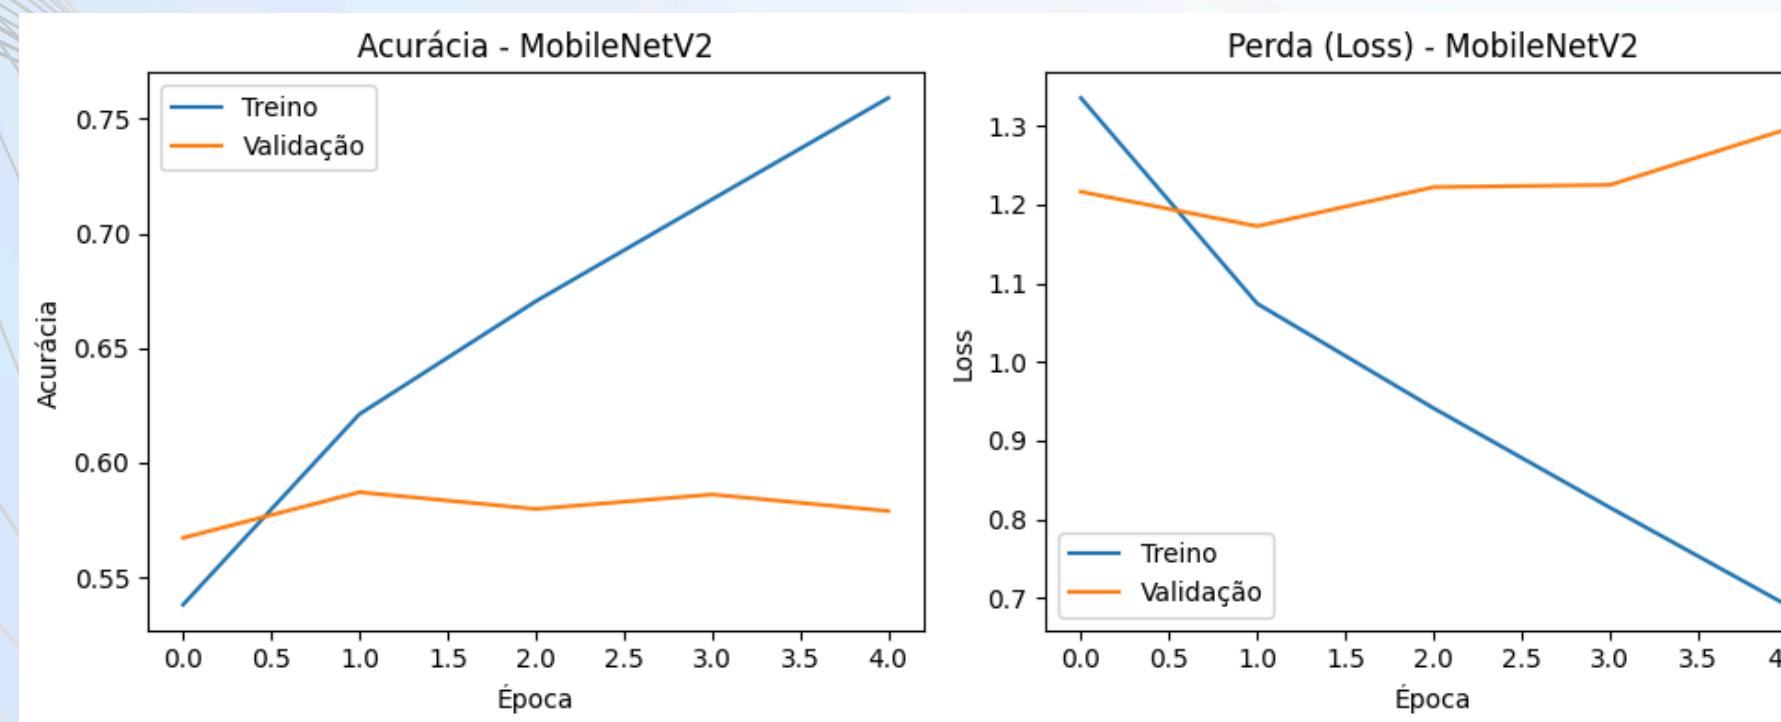
- Coleta de Dados
- Implementação e configuração dos modelos (pesos)
- Treinamento: monitorado por métricas
- Avaliação dos modelos com base em acurácia, perda e desempenho computacional.
- Comparação entre os resultados das duas arquiteturas.



RESULTADOS EXPERIMENTAIS



ResNet50: maior acurácia, porém maior tempo de processamento



MobileNetV2: menor consumo de recursos e resultados próximos.

- Gráficos demonstram comportamento de treinamento e validação.
- A escolha do modelo depende da necessidade: precisão ou eficiência.

CONFIGURAÇÃO TÉCNICA

Ambiente de Desenvolvimento

- **Plataforma:** Google Colab (Runtime GPU) > O Colab foi configurado com o runtime GPU, o que acelerou o treinamento das redes — especialmente a ResNet50, que tem muito mais parâmetros e exige processamento paralelo.
-  **Arquiteturas:** ResNet50 e MobileNetV2
-  **Linguagem:** Python
- **Bibliotecas principais:** TensorFlow, Keras, NumPy, Matplotlib, Pandas
- Treinei ambas as redes com o mesmo conjunto de dados

DISCUSSÃO E CONCLUSÃO

- Ambas as arquiteturas apresentaram bom desempenho.
- ResNet50: ideal para tarefas que exigem alta precisão.
- MobileNetV2: indicada para ambientes com recursos limitados.
- A decisão deve equilibrar acurácia e custo computacional.



AGRADECIMENTOS

Agradeço à Universidade Paranaense e ao meu orientador.
Obrigada à banca pela atenção e avaliação.

REFERÊNCIAS

- BISHOP, C. Pattern Recognition and Machine Learning. Springer, 2006.
- HAYKIN, S. Redes Neurais: princípios e prática. 2. ed. Porto Alegre: Bookman, 2001.
- HE, K. et al. Deep residual learning for image recognition. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.
- KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems, 2012.
- LECUN, Y. et al. Gradient-based learning applied to document recognition. Proceedings of the IEEE, v. 86, n. 11, p. 2278–2324, 1998.
- MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. Bulletin of Mathematical Biophysics, v. 5, p. 115–133, 1943.
- MINSKY, M.; PAPERT, S. Perceptrons: An Introduction to Computational Geometry. Cambridge: MIT Press, 1969.
- OLIVEIRA, D. F.; CÂMARA, G. Convolução em imagens digitais: fundamentos e aplicações. Revista Brasileira de Computação Aplicada, v. 11, n. 2, p. 45–56, 2019.
- DA SILVA, Henrique Coutinho Varela. Redes neurais de convolução na classificação de edifícios em imagens de alta resolução espacial. 2022. Dissertação de Mestrado. Universidade de Lisboa (Portugal).